

An Explainable Machine Learning Approach of PET Imaging for Individualized Predictions of Seizure Outcomes after Temporal Lobe Epilepsy Surgery

2022 GDMA Nuclear Medicine Annual Conference

Huanhua Wu
Prof. Hao Xu*

The First Affiliated Hospital of Jinan University

2022-11-29

Introduction

The Data

The Model

The Explanation

Conclusion

Introduction

Background

Epilepsy epidemiology

Aims

- 本实验基于真实的心脏病患者体侧数据，介绍如何通过数据挖掘算法构建心脏病预测模型。然而，本案例的目标不仅限于此——本案例着重分析机器学习模型的可解释性。



- 纸质版预计 2022 年 12 月 10 日上市（受北京疫情影响可能会晚约半个月）

The Data

Dinner



依赖关系

依赖关系

依赖关系

The Model

Benchmark

This text is centered.

基准测试 (benchmark), 用来比较不同学习器 (算法)、在多个任务 (数据) 和/或不同重抽样策略 (多个数据副本) 上的平均性能表现。

基准测试时有一个关键问题是, 测试的公平性, 即每个算法的每次测试必须在相同的重抽样训练集拟合模型, 在相同的重抽样测试集评估性能。

例如,

- 选取一个自带的二分类任务
- 选取多个学习器: 决策树、KNN、随机森林、支持向量机
- 创建基准测试“设计” (每个学习器不能只凭一次结果, 采用 5 折交叉验证的平均结果)
- 查看性能指标: 准确率、AUC 值
- 箱线图展示 AUC 值的对比结果

Introduction
○○○

The Data
○○○○

The Model
○○●○○

The Explanation
○○○○

Conclusion
○○○○○○○

参考文献

三. 图学习器

一个管道运算 (PipeOp), 表示机器学习管道中的一个计算步骤。一系列的 PipeOps 通过边连接 (%>>%) 构成图 (Graph), 图可以是简单的线性图, 也可以是复杂的非线性图。

这让我们可以像搭建积木一样, 搭建出复杂的图, 数据将沿着搭建好的图流动, 完成从预处理到机器学习算法构成的整个过程:

- ⇒ 选取 PipeOp, 通过 %>>%, gunion(), ppl() 等搭建图
- ⇒ Graph\$plot() 绘制图的结构关系;
- ⇒ as_learner(Graph) 将图转化为学习器, 即可跟普通学习器一样使用

管道、图学习器主要用于:

- ⇒ 特征工程: 缺失值插补、特征变换、特征选择、处理不均衡数据.....
- ⇒ 集成学习: 装袋法、堆叠法
- ⇒ 分支训练、分块训练

1. 特征工程

机器学习中的数据预处理，也统称为**特征工程**，主要包括：缺失值插补、特征变换，目的是提升模型性能。

- ⇒ 选择特征工程步相应的 PipeOp;
- ⇒ 多个特征工程步通过管道符%>>% 连接;
- ⇒ 很多 PipeOp 都支持 affect_columns 参数 (接受 Selector 选择器)

The Explanation




图 1: 特征工程管道示意图

- ⇒ 选择 3 个学习器：KNN、SVM、Ranger 作为三支分别拟合模型，再合并分支：
- ⇒ method: 调参方法，支持“grid_search”（网格搜索）、“random_search”（随机搜索）、gensa（广义模拟退火）、“nloptr”（非线性优化）。

六. 特征选择

当数据集包含很多特征时，只提取最重要的部分特征来建模，称为特征选择。特征选择可以增强模型的解释性、加速学习过程、改进学习器性能。

1. 过滤法

过滤法，基于某种衡量特征重要度的指标（如相关系数），用外部算法计算变量的排名，只选用排名靠前的若干特征，用 `mlr3filters` 包实现。

(1) 基于重要度指标

过滤法给每个特征计算一个重要度指标值，基于此可以对特征进行排序，然后就可以选出特征子集。

Conclusion

(2) 基于学习器的变量重要度

有些学习器可以计算变量重要度，特别是基于树的模型。有些学习器需要在创建时“激活”其变量重要性度量。例如，通过 `ranger` 包来使用随机森林的“impurity”度量：

使用上述特征选择可以对特征得分可视化，根据肘法确定保留特征数，然后用 `task$select()` 选择特征；也可以直接通过管道连接学习器构建图学习器：

2. 包装法

包装法，随机选择部分特征拟合模型并评估模型性能，通过交叉验证找到最佳的特征子集，用 `mlr3fselect` 包实现。

包装法特征选择，与超参数调参道理完全一样，支持：

- 独立特征选择过程： `fselect()`
- 自动特征选择器： `auto_fselector()`，封装成学习器，可用于重抽样或基准测试
- 嵌套重抽样特征选择： `fselect_nested()`

另外，有些学习器内部提供了选择有助于做预测的特征子集的方法，称为**嵌入法**。

七. 模型解释

可以从特征层面（特征效应、夏普利值、特征重要度）、观测层面（探索模型在单个观测上的表现）给出指标和可视化的模型解释，具体请参阅《R 机器学习：mlr3verse 技术手册》(?)。

For more theoretical approaches to machine learning model explanation, see [Interpretable Machine Learning: A Guide for Making Black Box Models Explainable](#), [What Causes Heart Disease? Explaining the Model](#), refer to [\(Rajpurkar, 2021\)](#), [\(Marc Becker, 2022\)](#), [\(Molnar, 2022\)](#)。

Email: wane199@outlook.com

GDMA 2022

12月2-4日
December 4-6

中国·深圳
Shenzhen, China

广东省医学会核医学学术年会



References I

Marc Becker, e. a. (2022). *mlr3book*.

Molnar, C. (2022). *Interpretable Machine Learning*. 2 edition.

Rajpurkar, P. S. (2021). *Deep Learning for Medical Image Interpretation*. Stanford University.